

Clasificación Multi-Clase de Radiografías de Tórax mediante Perceptrón Multicapa (MLP)

Nataly Lanchimba / Dario Herrera / Jordy Cevallos

Universidad Internacional del Ecuador

Profesor: Jefferson Rodriguez |

Código fuente

Proyecto en GitHub / Jupyter Notebook

1. Resumen del Problema

El presente proyecto se desarrolló a partir del conjunto de datos *ChestX6: Multi-Class X-ray Dataset*, disponible en la plataforma Kaggle. El objetivo consiste en predecir la condición pulmonar de un paciente a partir de imágenes de radiografías de tórax, clasificadas en seis categorías de enfermedades respiratorias. El problema se enmarca en la clasificación multiclase basada en características visuales como opacidades, infiltrados, consolidaciones y patrones de distribución en los pulmones.

Dado que las condiciones pulmonares presentan características visuales diferenciadas, se implementó un **Perceptrón Multicapa (MLP)** utilizando la API de alto nivel de **Keras/TensorFlow**, con el propósito de evaluar la capacidad de una arquitectura densa para resolver este tipo de tarea sobre imágenes médicas. La capa de salida emplea activación *softmax*, asignando una probabilidad a cada una de las seis clases posibles.




Figura 1: Muestra de radiografías por clase en el dataset.

El conjunto abarca seis clases de condiciones pulmonares: *Normal*, *Pneumonia-Bacterial*, *Pneumonia-Viral*, *COVID-19*, *Tuberculosis* y *Emphysema*. La Figura 2 muestra la distribución de imágenes por clase y por partición.




Figura 2: Distribución de imágenes por clase y subconjunto.

2. Preparación del Dataset

2.1. Descripción del Dataset

El *ChestX6* es un conjunto de imágenes de radiografías de tórax construido a partir de fuentes públicas, que incluye un total de **18 036 imágenes** en escala de grises, redimensionadas a 224×224 píxeles. La Figura 1 muestra una muestra representativa de cada clase.

Las características más relevantes del *dataset* se resumen en el Cuadro 1.

Cuadro 1: Ficha técnica del dataset ChestX6

Característica	Descripción
Número de muestras	18 036 imágenes
Modalidad	Radiografía de tórax
Espacio de color	Escala de grises (1 canal)
Resolución original	224 × 224 px
Resolución usada (MLP)	64 × 64 px
Nº de clases	6
Partición Train	14 551 imágenes (80.7 %)
Partición Validation	1 748 imágenes (9.7 %)
Partición Test	1 737 imágenes (9.6 %)
Tipo de tarea	Clasificación multiclase

2.2. Preprocesamiento del Dataset

Para adaptar las imágenes al formato de entrada del MLP, se aplicaron las siguientes transformaciones:

- **Redimensionamiento:** de 224×224 a 64×64 píxeles. Esta reducción disminuye el vector de entrada de 50 176 a **4 096 features**, haciendo el entrenamiento viable en equipos con recursos limitados, manteniendo suficiente información diagnóstica.
- **Normalización:** división por 255.0, mapeando los valores de píxel al rango $[0, 1]$ para acelerar la convergencia del gradiente.
- **Aumento de datos** (solo en entrenamiento): rotaciones ($\pm 10^\circ$), desplazamientos laterales ($\pm 5\%$) y volteos horizontales, para mejorar la generalización del modelo.
- **Codificación de etiquetas:** formato `class_mode='categorical'` generando representación *one-hot* para cada etiqueta.

La partición ya viene predefinida en el dataset (`train/val/test`), lo que elimina el riesgo de *data leakage*. Se respetó esta división oficial correspondiente a una proporción aproximada de **80/10/10**.

3. Implementación y Entrenamiento del Modelo

3.1. Arquitectura del MLP

El diseño del modelo busca clasificar los vectores de $64 \times 64 = 4096$ features en seis categorías de enfermedades. La arquitectura consiste en cuatro capas densas ocultas con reducción progresiva de unidades, intercaladas con *Batch Normalization* y *Dropout* para control de sobreajuste:

1. **Flatten:** convierte la imagen $(64, 64, 1)$ en vector de 4096 valores.
2. **Dense(1024) + BN + ReLU + Dropout(0.4)**
3. **Dense(512) + BN + ReLU + Dropout(0.3)**
4. **Dense(256) + ReLU + Dropout(0.3)**

5. Dense(128) + ReLU + Dropout(0.2)

6. Dense(6, Softmax): capa de salida probabilística.

Las decisiones de diseño se justifican de la siguiente manera: **ReLU** evita el problema del gradiente desaparecido y favorece la convergencia rápida; **Softmax** genera probabilidades mutuamente excluyentes para las seis clases; **Dropout** previene el sobreajuste en un dominio donde los modelos densos tienden a memorizar; **Batch Normalization** estabiliza el entrenamiento y permite tasas de aprendizaje más altas; la inicialización **He Normal** es óptima para activaciones ReLU.

En el Cuadro 2 se resume la configuración completa del modelo.

Cuadro 2: Configuración de la arquitectura MLP

Capa	Neuronas	Regularización
Flatten	4 096	—
Dense 1	1 024	BN + Dropout(0.4)
Dense 2	512	BN + Dropout(0.3)
Dense 3	256	Dropout(0.3)
Dense 4	128	Dropout(0.2)
Salida	6	Softmax
Función de pérdida		Cat. Crossentropy
Optimizador		Adam ($lr = 10^{-3}$)
Épocas máx.		40
Batch size		64

3.2. Entrenamiento

Se utilizaron tres *callbacks* para controlar el proceso de entrenamiento: **EarlyStopping** (paciencia=8, restaura mejores pesos), **ReduceLROnPlateau** (paciencia=4, factor=0.5) como *scheduler* de tasa de aprendizaje, y **ModelCheckpoint** para guardar el mejor modelo según `val_accuracy`.

4. Análisis de Técnicas de Mejora

Se realizó una comparación experimental entre tres optimizadores: **Adam**, **SGD con Nesterov** y **RMSProp**, manteniendo idéntica arquitectura y número de épocas (20) para una comparación justa. Los resultados se presentan en el Cuadro 3 y en la Figura 3.

Cuadro 3: Comparación de optimizadores

Optimizador	Val Loss	Val Acc	Épocas
Adam	0.808486	0.743707	20
SGD (Nesterov)	0.916123	0.773455	20
RMSProp	1.238785	0.618421	10




Figura 3: Curvas de pérdida y accuracy para los tres optimizadores.

5. Evaluación del Modelo

El rendimiento del modelo principal (Adam) se evaluó sobre el conjunto de prueba utilizando métricas de *accuracy*, precisión, *recall* y *F1-score*, junto con la matriz de confusión y el análisis de métricas por clase.

5.1. Métricas globales

Las curvas de entrenamiento y validación (Figura 4) muestran una convergencia estable sin sobreajuste significativo. El diagnóstico del *gap* train-val confirma una buena generalización del modelo.




Figura 4: Curvas de pérdida, accuracy y gap train-val.

El resumen de métricas sobre el conjunto de test se presenta en el Cuadro 4.

Cuadro 4: Métricas de evaluación en el conjunto de test

Métrica	Valor
Accuracy	0.8613
Precision (weighted)	0.8610
Recall (weighted)	0.8613
F1-Score (weighted)	0.8606
F1-Score (macro)	0.8621

5.2. Análisis por clase

La Figura 5 detalla las métricas de precisión, *recall* y *F1-score* por cada clase, permitiendo identificar las clases con mayor dificultad de clasificación para el modelo.



Figura 5: Precisión, Recall y F1-Score por clase.

5.3. Matriz de confusión

Las matrices de confusión (Figura 6) permiten identificar los patrones de error del modelo. Las confusiones más frecuentes se concentran entre *Pneumonia-Bacterial* y *Pneumonia-Viral*, lo cual es médicamente comprensible dada la similitud radiológica de ambas condiciones.




Figura 6: Matrices de confusión absoluta y normalizada.

5.3.1. Principales aciertos

- Clase *Normal*: alta separabilidad visual.
- Clase *Tuberculosis*: patrones morfológicos distintivos (cavitaciones en lóbulos superiores).

5.3.2. Errores notables

- Confusión entre *Pneumonia-Bacterial* y *Pneumonia-Viral*: solapamiento visual de infiltrados intersticiales.
- Dificultad en *COVID-19* vs. *Emphysema*: ambas presentan opacidades bilaterales difusas.

6. Conclusiones

1. El MLP alcanzó un rendimiento sólido para clasificación de imágenes médicas (Accuracy: 86.13 %). Considerando que el MLP trata cada imagen como un vector plano de 4096 valores perdiendo toda información espacial, lograr un 86.13 % de *accuracy* y un F1-macro de 0.86 sobre 1737 radiografías de seis enfermedades distintas representa un resultado competitivo. Esto valida que los patrones globales de intensidad

en radiografías son suficientemente discriminativos para un modelo denso, aunque una arquitectura CNN —que preserva relaciones espaciales— superaría este umbral.

[3] Scikit-learn developers (2024). Neural network models (supervised). https://scikit-learn.org/stable/modules/neural_networks_supervised.html

2. **La capacidad diagnóstica varía significativamente entre enfermedades según su distintividad visual.** *Tuberculosis* obtuvo el F1-score más alto (0.993, Recall=0.99), reflejando que sus patrones radiológicos —cavitaciones en lóbulos superiores y fibrosis— son morfológicamente únicos y fácilmente separables. En el extremo opuesto, *Pneumonia-Viral* registró el peor desempeño (F1=0.70, Precision=0.68), con el 23 % de sus casos confundidos con *Pneumonia-Bacterial*. Esta confusión es médicamente esperada: ambas condiciones comparten infiltrados intersticiales bilaterales difusos, diferenciables principalmente por marcadores clínicos y de laboratorio más que por apariencia radiológica.

3. **Adam demostró el mejor equilibrio entre error y estabilidad frente a SGD y RMSProp.** Adam obtuvo el menor *val loss* (0.808) completando las 20 épocas, lo que indica predicciones mejor calibradas y mayor confianza probabilística por clase. SGD alcanzó mayor *val accuracy* (0.773) pero con un *val loss* 13.4 % más alto, revelando predicciones menos seguras. RMSProp mostró el peor resultado general (*val accuracy*=0.618 a solo 10 épocas), sugiriendo que divergió prematuramente con la tasa de aprendizaje configurada. Para este problema, Adam es el optimizador recomendado por su convergencia estable y robustez ante hiperparámetros por defecto.

4. **El modelo generaliza bien globalmente pero requiere mejoras específicas en las clases de neumonía.** La consistencia entre Precision (0.861), Recall (0.861) y F1-Score (0.861) indica que el modelo no presenta sesgo hacia sobre-predecir ni sub-predecir clases, generalizando de forma equilibrada. Sin embargo, las clases *Pneumonia-Bacterial* (F1=0.76) y *Pneumonia-Viral* (F1=0.74) arrastran el desempeño global hacia abajo. Como pasos futuros se recomienda: implementar *transfer learning* con ResNet50 a resolución 224×224 , aplicar *focal loss* para penalizar más los errores en estas clases difíciles, y explorar técnicas de aumento de datos específicas que exageren las diferencias entre patrones bacterianos y virales.

6. Referencias

- [1] TensorFlow Documentation (2024). <https://www.tensorflow.org/>
- [2] Mohamed Asak (2024). *ChestX6: Multi-Class X-ray Dataset*. Kaggle. <https://www.kaggle.com/datasets/mohamedasak/chest-x-ray-6-classes-dataset>

Aprendizaje profundo Universidad Internacional del Ecuador
Semana 1